

**procura em contextos não-  
observáveis | determinísticos |  
conhecidos**

# procura local



não interessa o caminho até ao objetivo

ex: problema das rainhas, horários, otimização - de redes, de chão de fábrica, etc.

pode não se saber se já se atingiu o objetivo

se não sabemos o ótimo de uma função...

# paisagem do espaço de estados (a uma dimensão)



# trepacolas (*hill-climbing*)

maximização

# variante de maior subida (steepest ascent)

estado atual  $\leftarrow$  estado inicial aleatório

**repete**

    novo  $\leftarrow$  melhor dos vizinhos

**se** novo  $\leq$  estado atual **então retorna** estado atual (máximo local)

    estado atual  $\leftarrow$  novo

procura sôfrega

outras variantes: estocástico, reinício aleatório (meta algoritmo)

# problemas do trepa-colinas

máximos locais

cordilheiras (zonas com vários máximos locais)

planaltos

pode ultrapassar-se frequentemente permitindo  $n$  movimentos laterais (com valor idêntico ao atual)

o meta modelo reinício aleatório (*random restart*) melhora muito as possibilidades de encontrar o ótimo

# recozimento simulado (*simulated annealing*)

inicializa  $T$  (temperatura) # com um valor elevado

repete

escolhe aleatoriamente um sucessor do estado atual

se o sucessor for melhor passa a ser o estado atual

senão pode passar a ser o estado atual com probabilidade

$$P(\text{sucessor} \rightarrow \text{estado atual}) = e^{\Delta E / T}$$

#  $\Delta E \leq 0$  mede quão pior é o sucessor

reduz  $T$  # um degrau gradualmente

# recozimento simulado

análise

$$P(\text{sucessor} \rightarrow \text{estado atual}) = e^{\Delta E/T}$$

probabilidade de aceitação de um sucessor pior


diminui com  $T$  e com  $\Delta E (\leq 0)$

sucessores muito piores têm menos probabilidade de  
substituir o estado atual

“calendário” de diminuição da temperatura tem de ser lento

para permitir atingir o ótimo com probabilidade aproximando 1

# *simulated annealing*



fonte: wikipedia



# procura em feixe (*beam search*)

explora  $k$  estados (iniciados aleatoriamente)

repete

gera todos os sucessores dos  $k$  estados

$k$  sucessores são  
correlacionados  
(vs. multi-start hill-climbing)

→ seleciona os  $k$  melhores sucessores

na modalidade estocástica altera-se a linha assinalada para

→ seleciona probabilisticamente  $k$  sucessores  
com probabilidade proporcional à  
qualidade do sucessor

evita acumulação  
demasiado rápida  
dos estados  
numa região

# algoritmo genético (GA)

da família dos **algoritmos evolucionários**

modelos de inspiração biológica – evolução natural

- conjuntos de indivíduos, as soluções (inicialmente aleatórias)  
em cada ciclo são sujeitos a 4 operações sequencialmente
  - seleção
  - sobrecruzamento
  - mutação
  - substituição

# operadores genéticos

**seleção:** operador não-determinista, seleciona tendencialmente os melhores indivíduos

**sobrecruzamento:** combina duas soluções para obter dois descendente

**mutação:** altera aleatoriamente (com baixa probabilidade) as características de um indivíduo (solução)

**substituição:** produz a geração seguinte selecionando indivíduos dos descendentes e da geração anterior

# f. objetivo → f. de adaptação

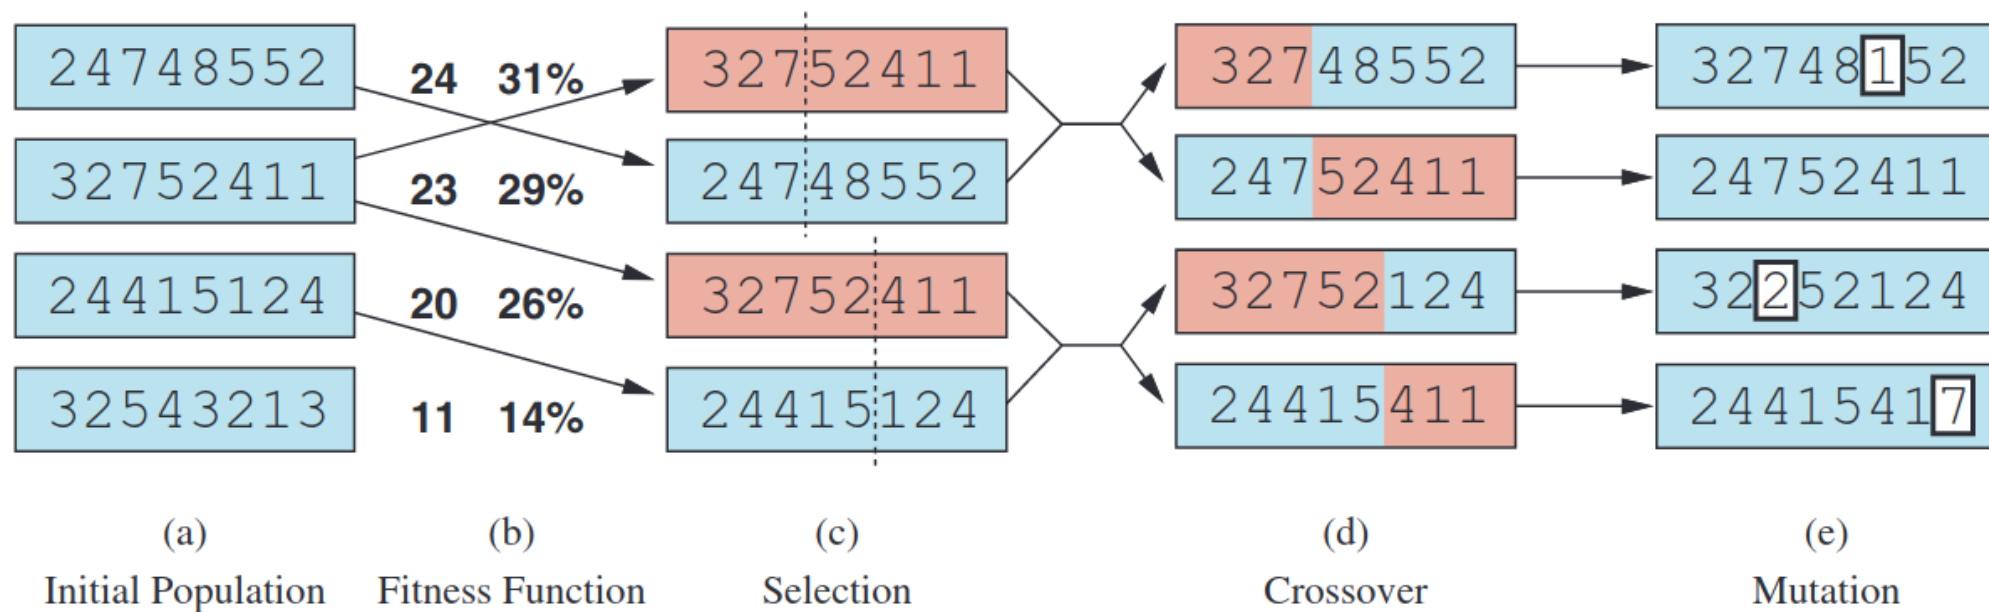
24748552

8		Q						
7					Q			
6					Q			
5								Q
4				Q				
3							Q	
2				Q				
1		Q						
	a	b	c	d	e	f	g	h
	1	2	3	4	5	6	7	8

função de adaptação:  
nº de pares que não se atacam  
(valor da solução: 28)

→ adaptação = 24

# exemplo de GA – 8 rainhas



fonte: AIMA

# comentários ao GA

método de procura local robusto

bons resultados na generalidade dos problemas

a variação das soluções é essencialmente baseada na seleção e no sobrecruzamento

mutação é um operador acessório

essencialmente para produzir novo material genético

# aspectos a notar na procura local

tabu search

a importância da vizinhança (HC, SA, BS, TS, ...)

quais as consequências de a vizinhança ser grande  
(ou seja, ter muitos sucessores)?

comparar estes algoritmos com os estudados na procura  
não informada

identificar semelhanças e complementaridades

# proc. local em espaços contínuos

adaptar a função de vizinhança:

- a) discretizar o espaço
- b) calcular o gradiente local da função

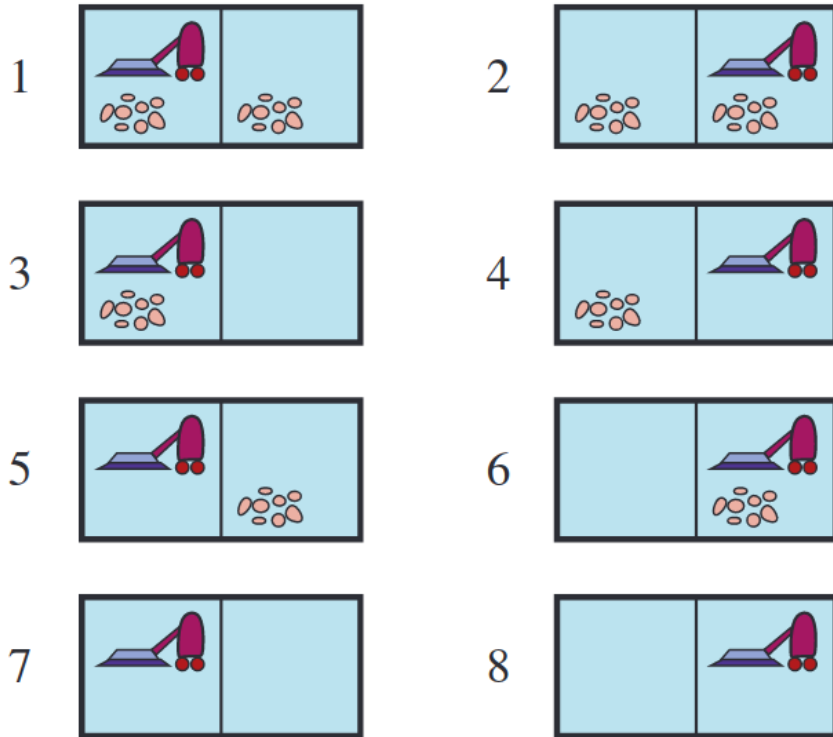
$$\nabla f = \left( \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

permite escolher a direção que provoca a maior melhoria  
é necessário definir o passo  $\alpha$

$$\mathbf{x} = \mathbf{x} + \alpha \nabla f(\mathbf{x})$$



# procura com ações não determinísticas



fonte: AIMA

supondo falhas ao aspirar:

pode limpar duas casas

pode depositar sujidade

começando no estado 1


plano de contingência

aspira

**se** Estado = 5 **então**

Direita, Aspira

# árvores E-OU (*AND-OR*)




ações do agente – nós OU  
result. no mundo – nós E


# plano a linhas grossas

- um objetivo em cada folha
- uma ação em cada nó OU
- todos os resultados em nós E

# ambientes parcialmente observáveis



(a) Possible locations of robot after  $E_1 = 1011$



(b) Possible locations of robot after  $E_1 = 1011, E_2 = 1010$

fonte: AIMA

sensores: Esq,Frt,Dir,Tra  
dada a crença inicial  $b$ , a ação  $a$ , e a nova percepção  $o$ , a nova crença é  
 $b' = \text{atualiza}(\text{predição}(b, a), o)$   
neste caso, após a 1ª ação, só há uma posição compatível

mas é necessário  
ter mapa do mundo!