



conhecimento incerto - representação probabilística

incerteza

por fatores externos ao planeador

ex: táxi - não controla trânsito e imprevistos

por espaço de procura demasiado vasto

por desconhecer como atuar em determinadas situações

por não conseguir determinar exatamente a situação

probabilidades

abordagem prática para lidar com incerteza

atribuição de probabilidades a acontecimentos incertos

quantifica a (in)certeza com um valor (probabilístico)

⇒ entre 0 e 1

nota: o máximo da incerteza não é quando a probabilidade é 0 ou 1! é quando todos os resultados são equiprováveis

entropia

decisões

um agente necessita ter em conta as probabilidades dos resultados das ações

e

as utilidades de cada ação e seus possíveis resultados

teoria da decisão = f(teoria de probabilidades, teoria da utilidade)

agente racional: escolhe a ação que tem a maior utilidade esperada, em média sobre todos os seus resultados possíveis

probabilidade conjunta (tabela)

um exemplo com três variáveis

	<i>dorDentes</i>		\neg <i>dorDentes</i>	
	<i>sonda</i>	\neg <i>sonda</i>	<i>sonda</i>	\neg <i>sonda</i>
<i>cárie</i>	0,108	0,012	0,072	0,008
\neg <i>cárie</i>	0,016	0,064	0,144	0,576

sonda: deteção
de um orifício
no dente

breve recap. de probabilidades

v.a. - inicial
maiúscula

valor da v.a.
- minúscula

$$P(a \vee b) = P(a) + P(b) - P(a \wedge b)$$

probabilidade da disjunção

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$

probabilidade condicional, função da conjunta

$$P(a, b) = P(a|b) P(b)$$

probabilidade conjunta, função da condicional

$$\mathbf{P}(Y) = \sum_{z \in Z} \mathbf{P}(Y, z)$$

probabilidade marginal

$$\mathbf{P}(Y) = \sum_z \mathbf{P}(Y|z) P(z)$$

probabilidade marginal, função da condicional

a partir da probabilidade condicionada

constante de normalização

$$P(cárie|dorDentes) = \frac{P(cárie, dorDentes)}{P(dorDentes)} = \frac{1}{P(dorDentes)} = \alpha$$

$$= \frac{0,108 + 0,012}{0,108 + 0,012 + 0,016 + 0,064} = 0,6$$

$$P(\neg cárie|dorDentes) = \frac{P(\neg cárie, dorDentes)}{P(dorDentes)}$$

$$= \frac{0,016 + 0,064}{0,108 + 0,012 + 0,016 + 0,064} = 0,4$$

usando a constante de normalização

$$\begin{aligned}\mathbf{P}(Cárie|dorDentes) &= \alpha \mathbf{P}(Cárie, dorDentes) \\ &= \alpha [\mathbf{P}(Cárie, dorDentes, sonda) + \mathbf{P}(Cárie, dorDentes, \neg sonda)] \\ &= \alpha [\langle 0,108; 0,016 \rangle + \langle 0,012; 0,064 \rangle] = \alpha \langle 0,12; 0,08 \rangle = \langle 0,6; 0,4 \rangle\end{aligned}$$

não é necessário saber o valor de α !
basta normalizar, de modo que a soma dê 1

$$\frac{0,12}{(0,12+0,08)} = 0,6$$

$$\frac{0,08}{(0,12+0,08)} = 0,4$$

inferência probabilística – caso de 3 v.a.

seja X a variável de que queremos saber as probabilidades

seja \mathbf{E} a lista das variáveis de evidência (ex: dorDentes)

seja \mathbf{e} a lista de valores observados das variáveis

e seja \mathbf{Y} a lista das restantes variáveis não observadas

$$\mathbf{P}(X|\mathbf{e}) = \alpha \mathbf{P}(X, \mathbf{e}) = \alpha \sum_{\mathbf{y}} \mathbf{P}(X, \mathbf{e}, \mathbf{y})$$

não escala bem!
para n v.a. booleanas
requer tabela $O(2^n)$ e
tempo de proc. $O(2^n)$

independência

suponhamos a v.a. $Tempo \in \{sol, chuva, nuvens, nevoeiro\}$

e a distribuição conjunta $\mathbf{P}\{DorDentes, Sonda, Cárie, Tempo\}$
(com 4 vezes a tabela da pág. 5)

mas o tempo não parece ser sinal de cáries
 \Rightarrow v.a. independentes

$$\mathbf{P}(DorDentes, Sonda, Cárie, Tempo) = \mathbf{P}(DorDentes, Sonda, Cárie) \mathbf{P}(Tempo)$$

$$\text{ou } \mathbf{P}(DorDentes|Tempo) = \mathbf{P}(DorDentes)$$

regra de Bayes

$$P(X|Y) = \frac{P(X, Y)}{P(Y)}$$

$$P(Y|X) = \frac{P(X, Y)}{P(X)}$$

logo

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

substituição da prob.
conjunta pela prob.
condicionada inversa

regra de Bayes

ou, com evidências

$$\mathbf{P}(Y|X, \mathbf{e}) = \frac{\mathbf{P}(X|Y, \mathbf{e})P(Y|\mathbf{e})}{P(X|\mathbf{e})}$$

formulação como causa e efeito

$$P(causa|efeito) = \frac{P(efeito|causa) P(causa)}{P(efeito)}$$

$P(efeito | causa)$ – relação na direção causal

$P(causa | efeito)$ – relação na direção de diagnóstico

médico conhece $P(sintomas | doença)$ e pretende diagnosticar: $P(doença | sintomas)$

ex. diagnóstico

meningite causa pescoço rígido 70% das vezes:

$$P(s|m) = 0,7$$

probabilidade de paciente com meningite:

$$P(m) = 1/50000 \quad \text{probabilidade a priori}$$

probabil. de paciente com pescoço rígido:

$$P(s) = 0,01 \quad \text{probabilidade a priori}$$

$$\text{donde: } P(m|s) = \frac{P(s|m)P(m)}{P(s)} = \frac{0,7 \times 1/50000}{0,01} = 0,0014$$

< 1/700 pescoço
rígido têm meningite
apesar de doença
dar sintoma em 70%,
mas doença é rara
e pescoço rígido não!

evidências combinadas

ex: *dorDentes* e *sonda*

sabendo a distribuição conjunta (tab. pg. 5)

$$\mathbf{P}(Cárie|dorDentes, sonda) = \alpha \langle 0,108; 0,016 \rangle = \langle 0,871; 0,129 \rangle$$

mas a distr. conjunta não escala com o nº de variáveis!

usando a regra de Bayes:

$$\mathbf{P}(Cárie|dorDentes, sonda) = \alpha \mathbf{P}(dorDentes, sonda|Cárie) \mathbf{P}(Cárie)$$

que também não escala bem...

hélas!

independência condicionada

na realidade, *dorDentes* e *sonda* são independentes dada a presença ou ausência de cárie

a cárie provoca dor de dentes e cria orifício (sonda positiva)

ou seja

$$\mathbf{P}(dorDentes, sonda|Cárie) = \mathbf{P}(dorDentes|Cárie) \mathbf{P}(sonda|Cárie)$$

donde

$$\begin{aligned} \mathbf{P}(Cárie|dorDentes, sonda) &= \\ &= \alpha \mathbf{P}(dorDentes|Cárie) \mathbf{P}(sonda|Cárie) \mathbf{P}(Cárie) \end{aligned}$$

indep. condicionada em geral

formulação geral (mais forte, porque é com as v.a.)

$$\mathbf{P}(X, Y|Z) = \mathbf{P}(X|Z) \mathbf{P}(Y|Z)$$

no caso da dentista

$$\mathbf{P}(DorDentes, Sonda|Cárie) = \mathbf{P}(DorDentes|Cárie) \mathbf{P}(Sonda|Cárie)$$

independência condicionada escala!

em variáveis binárias passa de $O(2^n)$ para $O(n)$

conceito muito importante para a IA, em particular na Aprendizagem Automática

classificador naive Bayes

caso geral

$$\mathbf{P}(Causa, Efeito_1, \dots, Efeito_n) = \mathbf{P}(Causa) \prod_i \mathbf{P}(Efeito_i | Causa)$$

é considerado “naive” porque nem sempre todos os efeitos são independentes dada a causa

surpreendentemente, tem frequentemente muito bons resultados, mesmo quando a independência condicional não se verifica

rede Bayesiana

é uma estrutura suficiente para representar a distrib. conjunta de todas as variáveis!

estrutura em grafo de representação de conhecimento probabilístico

cada nó representa uma v.a.

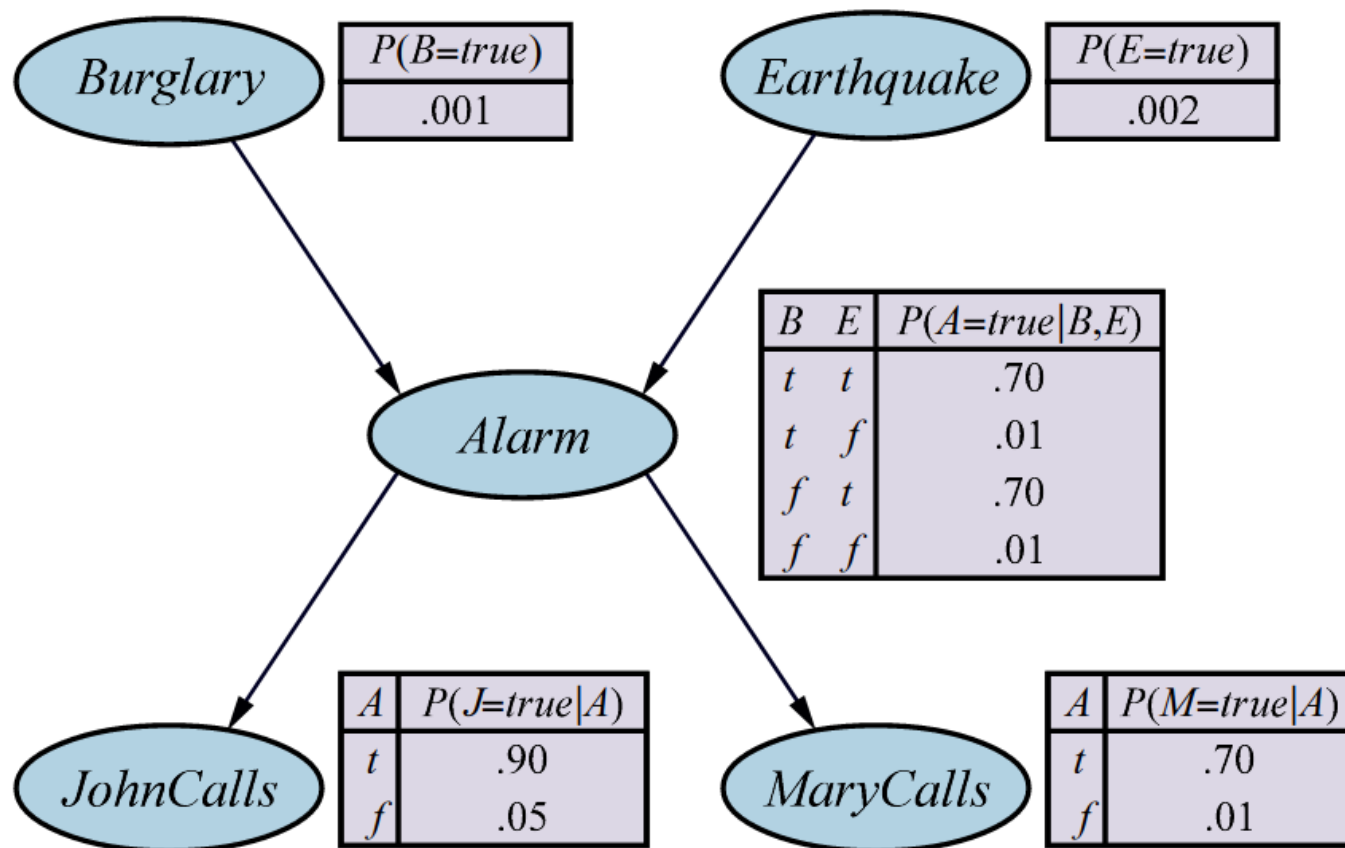
arco do nó X para o nó Y , refere-se como X é pai de Y

cada nó X_i tem uma distribuição de probabilidade condicional, $P(X_i | Pais(X_i))$, que quantifica os efeitos dos pais no nó

ideia: os pais representam as causas e os filhos representam os efeitos

modelo causal simplifica a rede, face ao modelo diagnóstico e facilita definição das probabilidades

um exemplo (clássico)



separação (variáveis escondidas)

representação em rede de Bayes é muito económica
comparar com uma tabela com $2^5 = 32$ linhas de 5 valores cada

a variável $A(larme)$ “esconde” as variáveis B e E
das variáveis J e M

tornando J e M diretamente independentes de B e E
 J e M são independentes entre si dada a variável A

rede de Bayes não tem redundância!

não há o risco de falhar a lei das probabilidades

experimental

calcular as probabilidades de:

a Mary telefonar dado que houve um tremor de terra

haver um assalto dado que o John telefonou