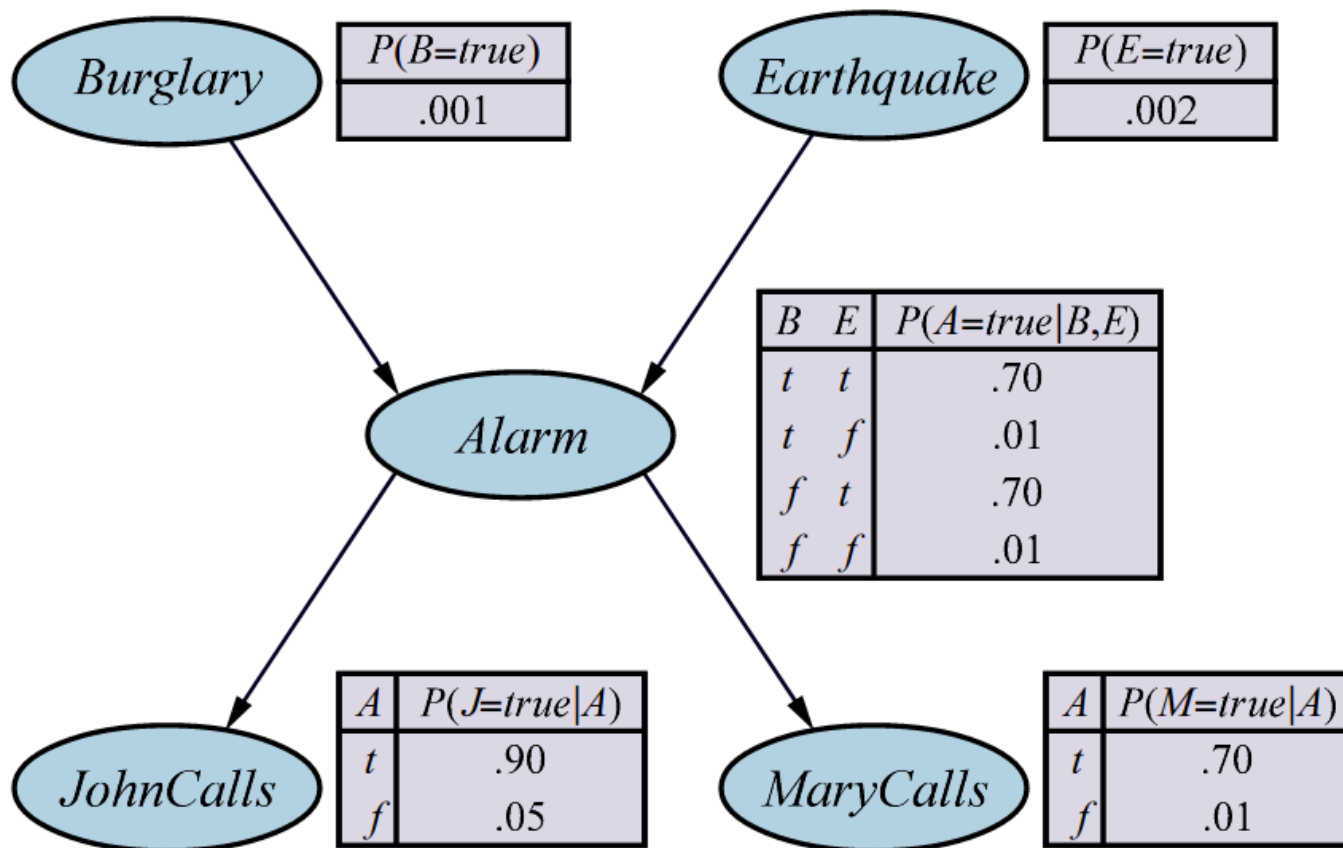


conhecimento incerto - inferência

rede Bayesiana (recap.)



representação
eficiente de
conhecimento
probabilístico


as tabelas de
probabilidades
condicionadas
permitem obter
as probabilidades
conjuntas

propriedades da rede Bayesiana

uma variável é
condicionalmente independente
dos seus **não-descendentes**
dados os seus pais

ex: X é condicionalmente
independente dos nós Z_{ij} dados
 U_i

J é independente de B , E e M
dado $A(larm)$




propriedades II

um nó é condicionalmente independente de todos os outros nós da rede dados os seus pais, descendentes e pais dos descendentes – **manto de Markov**

X é independente de todo o resto da rede dados U_i , Z_{ij} e Y_i

B é independente de J e M dado $A(larm)$ e E



inferência exata em redes Bayesianas

consiste em:

calcular a probabilidade de variáveis *questionadas (query)*, dadas variáveis *evidência*

X – variáveis questionadas

E – variáveis evidência

Y – variáveis escondidas (não questionadas, não evidência)

ex: $P(X \mid e)$

$$P(B \mid J=t, M=t) = \langle 0,284, 0,716 \rangle$$

inferência por enumeração

já vimos que $\mathbf{P}(X|\mathbf{e}) = \alpha \mathbf{P}(X, \mathbf{e}) = \alpha \sum_y \mathbf{P}(X, \mathbf{e}, y)$

e que não
escala bem!

ex. da pg. anterior: $\mathbf{P}(B|j, m) = \alpha \mathbf{P}(B, j, m) = \alpha \sum_e \sum_a \mathbf{P}(B, j, m, e, a)$

em que e e a , são os valores das v.a. E e A

em redes Bayesianas (para $B = t$)

$$P(b|j, m) = \alpha \sum_e \sum_a P(b) P(e) P(a|b, e) P(j|a) P(m|a)$$

complexidade, com n v.a. booleanas, $O(n2^n)$

melhorando...

$$P(b|j, m) = \alpha \sum_e \sum_a P(b) P(e) P(a|b, e) P(j|a) P(m|a)$$

pode rescrever-se

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$

ainda assim tem complexidade temporal $O(2^n)$ para n variáveis booleanas

eliminação de variáveis

algoritmo mais simples que faz as contas apenas uma vez e guarda para uso futuro (em que aparece a mesma expressão)

$$\mathbf{P}(B|j, m) = \alpha \underbrace{\mathbf{P}(B)}_{\mathbf{f}_1(B)} \underbrace{\sum_e P(e)}_{\mathbf{f}_2(E)} \underbrace{\sum_a \mathbf{P}(a|B, e)}_{\mathbf{f}_3(A, B, E)} \underbrace{P(j|a)}_{\mathbf{f}_4(A)} \underbrace{P(m|a)}_{\mathbf{f}_5(A)}$$

de notar que $\mathbf{f}_4(A)$
e $\mathbf{f}_5(A)$ só dependem
de A , porque J e M são
fixados pela questão

$$\mathbf{f}_4 = \begin{pmatrix} P(j|a) \\ P(j|\neg a) \end{pmatrix} = \begin{pmatrix} 0,90 \\ 0,05 \end{pmatrix}$$

$$\mathbf{f}_5 = \begin{pmatrix} P(m|a) \\ P(m|\neg a) \end{pmatrix} = \begin{pmatrix} 0,70 \\ 0,01 \end{pmatrix}$$

$\mathbf{f}_3(A, B, E)$ é uma matriz
de $2 \times 2 \times 2$

1º elemento $P(a | b, e) = 0,95$
últ. elem $P(\neg a | \neg b, \neg e) = 0,999$

avaliação

usando a fatorização

produto
pontual

$$\mathbf{P}(B|j, m) = \alpha \mathbf{f}_1(B) \times \sum_e \mathbf{f}_2(E) \times \sum_a \mathbf{f}_3(A, B, E) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A)$$

da direita para a esquerda somando fora variáveis

$$\begin{aligned} \mathbf{f}_6(B, E) &= \sum_a \mathbf{f}_3(A, B, E) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A) \\ &= (\mathbf{f}_3(a, B, E) \times \mathbf{f}_4(a) \times \mathbf{f}_5(a)) + (\mathbf{f}_3(\neg a, B, E) \times \mathbf{f}_4(\neg a) \times \mathbf{f}_5(\neg a)) \end{aligned}$$

$$\text{donde } \mathbf{f}_7(B) = \sum_e \mathbf{f}_2(E) \times \mathbf{f}_6(B, E) = \mathbf{f}_2(e) \times \mathbf{f}_6(B, e) + \mathbf{f}_2(\neg e) \times \mathbf{f}_6(B, \neg e)$$

finalmente $\mathbf{P}(B|j, m) = \alpha \mathbf{f}_1(B) \times \mathbf{f}_7(B)$ que pode ser avaliada diretamente

produto pontual

\times é o produto pontual

o produto pontual de dois fatores \mathbf{f}_1 e \mathbf{f}_2 é um fator \mathbf{f} cujas variáveis são a união das de \mathbf{f}_1 e \mathbf{f}_2 e os valores são os produtos dos elementos correspondentes em ambos

ex: se as variáveis Y_1, \dots, Y_k são comuns a \mathbf{f}_1 e \mathbf{f}_2

$$\mathbf{f}(X_1 \dots X_j, Y_1 \dots Y_k, Z_1 \dots Z_l) = \mathbf{f}_1(X_1 \dots X_j, Y_1 \dots Y_k) \mathbf{f}_2(Y_1 \dots Y_k, Z_1 \dots Z_l)$$

produto pontual (ex.)

X	Y	$\mathbf{f}(X, Y)$	Y	Z	$\mathbf{g}(Y, Z)$	X	Y	Z	$\mathbf{h}(X, Y, Z)$
t	t	.3	t	t	.2	t	t	t	$.3 \times .2 = .06$
t	f	.7	t	f	.8	t	t	f	$.3 \times .8 = .24$
f	t	.9	f	t	.6	t	f	t	$.7 \times .6 = .42$
f	f	.1	f	f	.4	t	f	f	$.7 \times .4 = .28$
<div>multiplicam-se os elementos com o valor de Y em comum</div>						f	t	t	$.9 \times .2 = .18$
						f	t	f	$.9 \times .8 = .72$
						f	f	t	$.1 \times .6 = .06$
						f	f	f	$.1 \times .4 = .04$

somar fora uma variável

somar as sub-matrizes com cada valor da variável

ex:

$$\begin{aligned} \mathbf{f}(B, C) &= \sum_a \mathbf{f}_3(A, B, C) = \mathbf{f}_3(a, B, C) + \mathbf{f}_3(\neg a, B, C) \\ &= \begin{pmatrix} 0,06 & 0,24 \\ 0,42 & 0,28 \end{pmatrix} + \begin{pmatrix} 0,18 & 0,72 \\ 0,0,6 & 0,04 \end{pmatrix} = \begin{pmatrix} 0,24 & 0,96 \\ 0,48 & 0,32 \end{pmatrix} \end{aligned}$$

reordenam-se as variáveis de modo a ficar no somatório só com as que vão ser somadas ex, somar fora E em

$$\sum_e \mathbf{f}_2(E) \times \mathbf{f}_3(A, B, E) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A) = \mathbf{f}_4(A) \times \mathbf{f}_5(A) \times \sum_e \mathbf{f}_2(E) \times \mathbf{f}_3(A, B, E)$$

variáveis irrelevantes para a questão

supondo a questão $\mathbf{P}(JohnCalls|Burglary=true)$

$$\mathbf{P}(J|b) = \alpha P(b) \sum_e P(e) \sum_a P(a|b,e) \mathbf{P}(J|a) \sum_m P(m|a)$$

verifica-se de imediato $\sum_m P(m|a) = 1$

e pode aplicar-se:

qualquer variável que não seja antecedente da variável questionada, ou uma variável de evidência, é irrelevante para a questão e pode ser eliminada antes de avaliar a questão

complexidade da inferência exata

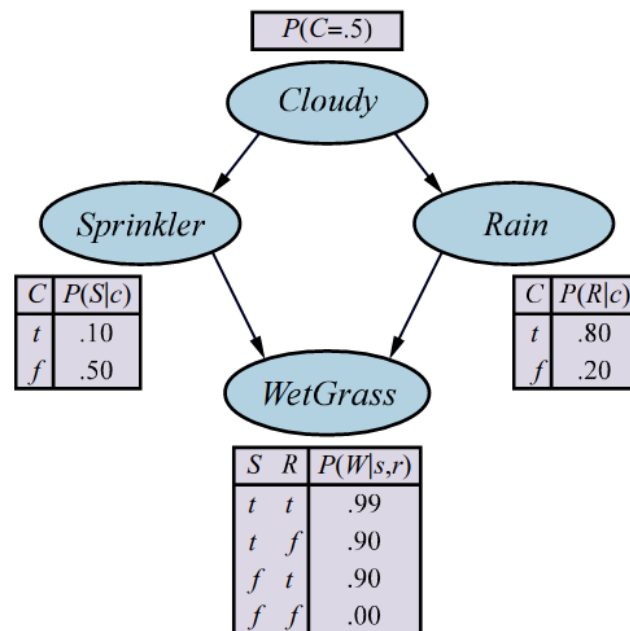
polytrees – há no máximo um caminho entre dois nós

nestas estruturas a eliminação de variáveis tem complexidade espacial e temporal lineares com a dimensão da rede

redes multiplamente conectadas

eliminação de variáveis pode ter complexidade temporal e espacial exponenciais

mesmo com número de pais por nó limitado!



inferência aproximada em redes Bayesianas

visto o problema da inferência exata ser intratável para redes grandes...

fazem-se amostragens de Monte Carlo (aleatórias)

dois métodos práticos:

- amostragem direta
- amostragem por cadeia de Markov

amostragem direta

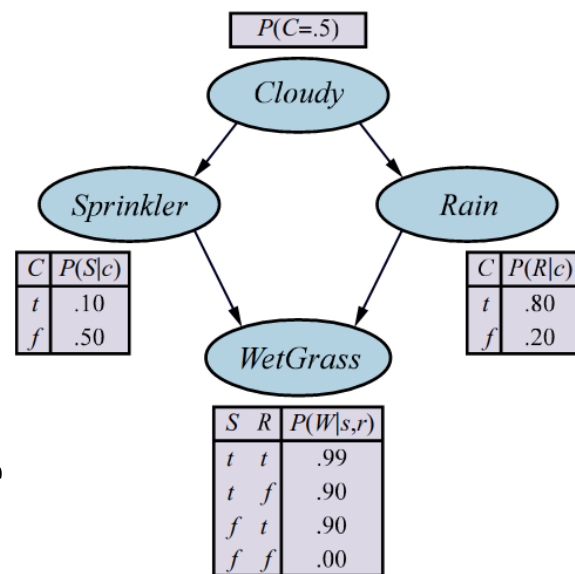
amostrar cada variável em ordem topológica

a distribuição de cada amostragem é condicionada aos valores já atribuídos aos pais

ex:

1. amostra de $\mathbf{P(Cloudy)=\langle 0,5; 0,5 \rangle}$, valor *true*
2. amostra de $\mathbf{P(Sprinkler|Cloudy=true)=\langle 0,1; 0,9 \rangle}$, valor *false*
3. amostra de $\mathbf{P(Rain|Cloudy=true)=\langle 0,8; 0,2 \rangle}$, valor *true*
4. amostra de $\mathbf{P(WetGrass|Sprinkler=false, Rain=true)=\langle 0,9; 0,1 \rangle}$, valor *true*

amostra retorna [*true*, *false*, *true*, *true*]



probabilidade estimada

probabilidade de amostrar evento (x_1, \dots, x_n) :

$$S_{PS}(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{pais}(X_i)) = P(x_1, \dots, x_n)$$

contam-se os eventos N e:

$$\lim_{N \rightarrow \infty} \frac{N_{PS}(x_1, \dots, x_n)}{N} = S_{PS}(x_1, \dots, x_n) = P(x_1, \dots, x_n)$$

resultado da amostragem $\frac{N_{PS}(x_1, \dots, x_n)}{N} = \hat{P}(x_1, \dots, x_n) \approx P(x_1, \dots, x_n)$

amostragem com rejeição

pretende-se determinar $\mathbf{P}(X|\mathbf{e})$

obtêm-se amostras da rede

rejeitam-se as que não condizem com a evidência

$$\text{estimativa: } \hat{\mathbf{P}}(X|\mathbf{e}) = \frac{N_{PS}(X, \mathbf{e})}{N_{PS}(\mathbf{e})}$$

ex: obter $\hat{\mathbf{P}}(\text{Rain}|\text{Sprinkler}=\text{true})$ com 100 amostras

em 73 delas *Sprinkler=false*, são rejeitadas, das 27 restantes

Rain=true em 8 e *Rain=false* em 19, logo

$$\hat{\mathbf{P}}(R|S=t) = \alpha(\langle 8; 19 \rangle) = \langle 0,296; 0,704 \rangle$$

rejeição cresce
exponencialmente
com v.a.s de
evidência!

Markov chain Monte Carlo (MCMC)

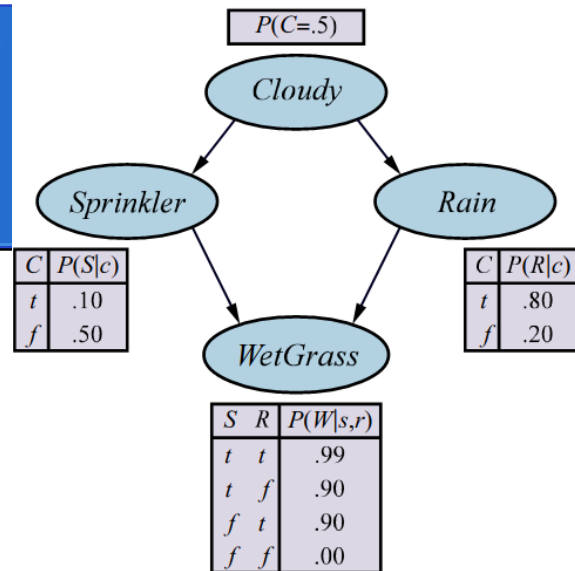
em vez de gerar cada amostra desde o início,
cada amostra é uma pequena alteração da anterior

- a amostragem Gibbs (uma forma de MCMC)

começa num estado arbitrário com as v.a. de evidência fixadas
nos valores observados

gera um novo estado amostrando aleatoriamente uma das
variáveis não evidência, X_i , condicionado ao valor corrente das
v.a. do manto de Markov de X_i

ex. Gibbs MCMC



queremos saber $\mathbf{P}(Rain|Sprinkler=true, WetGrass=true)$

são fixadas: $S=t$ e $W=t$ estado inicial: $[t, t, f, t]$

e inicializadas aleatoriamente: $C=t$ e $R=f$

e C e R amostradas repetidamente em ordem aleatória

1. C amostrada dados os valores do manto de Markov
i.e. de $\mathbf{P}(C | S=t, R=f)$. Supondo $C=f$, o estado é $[f, t, f, t]$
2. R amostrada dados os valores do manto de Markov
i.e. de $\mathbf{P}(R | C=f, S=t, W=t)$. Supondo $R=t$, o estado é $[f, t, t, t]$

cada estado é uma amostra

se em 20 $R=t$ e em 60 $R=f$, então $\hat{\mathbf{P}}(R|s, w) = \alpha(\langle 20; 60 \rangle) = \langle 0,25; 0,75 \rangle$

outros modelos de incerteza

teoria de Dempster-Shafer

função de crença (*Belief*): $Bel(A) + Bel(\neg A) \leq 1$

uma versão pessimista de probabilidade...

conjuntos difusos e lógica difusa

representação de pertença em categorias de limites definidos de uma forma contínua em vez de em degraus disjuntos

e inferência sobre essas representações

